

FurniRecon: Optimización de Redes Neuronales Convolucionales y Máquinas de Soporte Vectorial para el Reconocimiento de Imágenes de Mobiliario

Carolina Calvache¹, Santiago Salazar², Daniel F. Tovar³

¹Maestría en Inteligencia Artificial.

²Maestría en Ingeniería de Sistemas y Computación.

³Maestría en Analítica para la Inteligencia de Negocios.

^{1*}Ingeniería, Pontificia Universidad Javeriana, Bogotá D.C, 111321, Colombia.

Contributing authors: calvache.leidy@javeriana.edu.co;
agustin.salazar@javeriana.edu.co; tovar.daniel@javeriana.edu.co;

Abstract

Nowadays, technology is giving rise to new services and platforms for products. Digital transformation since COVID-19 has shifted from being optional to being essential. Current instances of companies that resisted transforming their business models, due to inability or stubbornness, have faced extinction, reminiscent of the fate of Blockbuster. According to numerous studies, A.I. is predicted to trigger one of history's most profound revolutions, with a multitude of companies set to implement it in the coming years. Consequently, businesses not prepared for this new digitally personalized world risk being consumed by the competitive landscape and evolving market. Among these markets, interior design stands out, and notably, significant suppliers can play a crucial role, but only if they undergo a digital transformation by offering their products, for instance, through augmented reality or the metaverse. This trend towards personalization and the creation of immersive realities will gain even more relevance in the upcoming years, presenting a perfect opportunity to ride this wave. Thus, we present the problem, analyze the tools, variables, and methods required to create a saleable service for these companies. This service empowers them to transform their business models through a more digital sales approach while we are exploring different viewpoints on methods and tools for creating this service.

Keywords: FurniRecon, CNN, SVM, Reconocimiento de Imágenes

1 Introducción

La Inteligencia Artificial avanza rápidamente, y ahora existen una gran cantidad de servicios y soluciones. No es sorprendente, dado que las herramientas científicas y el conocimiento matemático fueron inventados hace décadas. Sin embargo, solo a principios de la década de 2010 surgieron nuevas herramientas capaces de registrar una vasta cantidad de datos. El crecimiento en capacidad de 2010 a 2020 fue de más del 3100 por ciento, aproximadamente, y se espera que crezca del 2020 al 2025 en un 185% adicional [1]. La única "parte faltante" de la IA era la capacidad de procesamiento, y desde 2015 hasta ahora (junio de 2023), el crecimiento ha sido de más del 1300% [2]. Estas estadísticas nos muestran por qué la IA se está volviendo tan relevante en estos días.

Según "El Futuro de los Empleos", el 75 por ciento de las empresas planean adoptar servicios de IA [3]; por lo tanto, las empresas y startups deben adoptar esta nueva tecnología para seguir siendo competitivas en este mercado en evolución. Sin embargo, no se trata solo de tener chatbots o sistemas de recomendación; estos son casi una necesidad en la actualidad. Esto también implica que deben renovar sus modelos de negocios y someterse a una transformación digital más integral en todos los procesos y áreas, especialmente en el ámbito del marketing [4].

Con estas consideraciones en mente, nuestra propuesta es un servicio impulsado por IA capaz de crear una vista de Realidad Aumentada de varios espacios habitables dentro de una casa o apartamento. Logramos esto a través de un modelo generativo que presenta productos vendidos por nuestros clientes. Este servicio de Realidad Aumentada debe reconocer primero diferentes tipos de muebles y estilos. Este reconocimiento nos permite proporcionar al consumidor final recomendaciones informadas sobre los productos de nuestro cliente y cómo se combinan con los muebles y el estilo existentes. Además, el servicio incluye un sistema de recomendación para los usuarios, sugiriendo enfoques alternativos para sus espacios vitales basados en el nuevo estilo deseado. Estos enfoques utilizando Realidad Aumentada han demostrado un aumento en las ventas, pero también un aumento en las ventas de productos de mayor precio [5].

Dado el alcance sustancial de este servicio, actualmente nos estamos enfocando en las fases iniciales. Específicamente, nos estamos concentrando en desarrollar el modelo de reconocimiento para tres tipos distintos de muebles y un estilo particular, como se menciona en la sección de descripción de la tarea.

2 Estado del Arte

La clasificación de imágenes mediante el uso de inteligencia artificial ha experimentado notables avances, transformando fundamentalmente la forma en que interactuamos con datos visuales en diversas disciplinas. Este estado del arte destaca los hitos más relevantes y las tendencias emergentes en el ámbito de la clasificación de imágenes impulsada por la inteligencia artificial.

2.1 Revisión Literaria

Investigaciones como la de Robinson Jiménez Moreno, Oscar Avilés S. y Diana Ovalle (2018) han sido fundamentales en el desarrollo de arquitecturas de redes neuronales convolucionales (CNN) para la clasificación de imágenes en herramientas comunes utilizadas en tareas de mecánica, electricidad, carpintería, y áreas similares. El modelo propuesto, estableció nuevos estándares al demostrar una mejora significativa en la precisión de la clasificación en comparación con enfoques convencionales logrando un accuracy del 96,1 % [6]

La eficacia comprobada de las Redes Neuronales Convolucionales (RNC) en la extracción y mapeo de características para la clasificación de imágenes se destaca en la literatura científica. Este enfoque ha generado resultados prometedores, consolidando su importancia en el ámbito de la investigación. En el estudio presentado por Néstor E. Suat (2020), se adoptó un enfoque innovador centrado en la clasificación de imágenes de señas sin movimiento del abecedario. Para lograr esto, se integraron técnicas avanzadas de procesamiento de imágenes con el poder de las redes neuronales. [7]

Samir Kanaan y Carles Ventura R (2016) desarrollaron un sistema capaz de reconocer el contenido de las matrículas de los vehículos a partir de las imágenes capturadas por una cámara fotográfica, de esta manera fortalecen las redes neuronales convolucionales en el desafío de la clasificación de imágenes. Además, resaltan la importancia de contar con un conjunto de imágenes de entrenamiento lo suficientemente extenso y representativo del problema, factor determinante para alcanzar resultados satisfactorios con una red neuronal convolucional. [8]

En su estudio sobre lógica difusa diversa, Lingling Zhang y Minna Leu resaltan la relevancia de supervisar la diversidad de los centros de los grupos de imágenes para prevenir sesgos en el proceso de agrupamiento durante el clustering. Además, destacan que, a diferencia del método Fuzzy c-means, que tiende a prestar más atención al grupo más grande y no logra identificar de manera precisa los grupos más pequeños, el enfoque Fuzzy c-means diverso demuestra una capacidad más efectiva en la identificación de estos últimos.

Otros experimentos, como el de Kou Long Wu (2011) estudiaron al fuzzificador como una alternativa para determinar la probabilidad de pertenencia de un punto de datos a cada clúster. La función de fuzzificación desempeña un papel fundamental en el algoritmo Fuzzy C-Means, permitiendo que cada punto de datos tenga un grado de pertenencia en varios clústeres en función de su proximidad a los centroides. El experimento indica que desde el punto de vista de la robustez un fuzzificador grande hará que FCM sea más robusto al ruido y los valores atípicos.

Finalmente, en la revisión realizada para múltiples funciones de núcleo en el contexto de problemas de segmentación de imágenes, Long Chen (2009) muestra que las funciones del núcleo se componen de diferentes núcleos seleccionados para representar diversas propiedades o información de los píxeles de la imagen. Además, de resaltar las

funciones de núcleo diferentes de manera deliberada para la información de intensidad y la información de textura por separado generan mayor exactitud en la clasificación de imágenes. [9]

3 Metodología FurniRecon

La metodología de FurniRecon involucra la implementación de una red neuronal convolucional para la extracción de características de imágenes de mobiliario, seguida de la integración de una máquina de soporte vectorial para la clasificación precisa.

A continuación, se describe en detalle cada fase de la metodología, destacando su importancia dentro del desarrollo FurniRecon:

1. Recopilación: En esta etapa, se lleva a cabo la obtención de información relevante y necesaria para alimentar el modelo que se va a desarrollar. Este proceso implica la identificación de fuentes de datos pertinentes.

Aprovechando el conjunto de datos "Furniture" de Kaggle [10], esta colección completa consta de 9,350 imágenes que varían en tamaño desde 100x100 píxeles hasta 300x300 píxeles. Cabe destacar que no todas las imágenes tienen forma cuadrada. El conjunto de datos está anotado con ocho etiquetas distintas, a saber, "Bed/Bedroom item" (3,043 imágenes), "Table/Chair" (2,419 imágenes), "Sofa/Livingroom Item" (1,813 imágenes), "Storage" (1,326 imágenes), "Other" (270 imágenes), "TV" (244 imágenes), "Antique" (209 imágenes), "Textiles" (21 imágenes) y "Lightning" (1 imagen). En la mayoría de nuestros experimentos, nos enfocamos en las primeras cuatro etiquetas, cada una de las cuales contiene más de 1,000 imágenes. Este enfoque selectivo se adopta debido a la ineficiencia de entrenar modelos con conjuntos de datos que contienen 270 imágenes o menos.




Fig. 1: Distribution of images by label.

2. Visualización y exploración: La visualización y exploración de datos se centra en la comprensión inicial del conjunto de datos recopilado. Esta etapa tiene como objetivo revelar patrones, tendencias y relaciones entre variables, proporcionando una visión intuitiva que facilita la identificación de insights y la toma de decisiones informadas, en este caso, esta es una muestra del dataset




Fig. 2: Muestra del dataset.

3. Limpiar Datos: Este proceso abarca diversas tareas, comenzando por la identificación y tratamiento de datos faltantes, duplicados o erróneos, se busca asegurar la coherencia y la integridad de la información, eliminando posibles errores que podrían afectar la validez de los resultados finales, en nuestro caso, aunque los modelos fueron ejecutados en una máquina específica, nos enfrentamos a un problema en equipos con sistema operativo Windows, donde más de 6000 imágenes se perdían debido a problemas con caracteres especiales en el conjunto de datos, por esta razón, decidimos ejecutar los modelos siempre en un dispositivo con MacOS.

Además, como mencionamos al principio, solo vamos a utilizar 4 etiquetas en los experimentos, aquellas que cuentan con más de 1000 imágenes.

4. Vista minable: Se seleccionaron imágenes de manera aleatoria para llevar a cabo el reconocimiento de cada categoría. Observando que el sistema no solo identifica camas, sino que también reconoce armarios como parte de la categoría del dormitorio (Vista minable no estructurados)



Fig. 3: Metodología

3.1 Implementación de la CNN

La arquitectura de la Convolutional Neural Network (CNN) implementada en FurniRecon integra varias capas convolucionales, cada una seguida por funciones de activación ReLU, el modelo puede aprender representaciones jerárquicas y complejas de las características presentes en las imágenes de muebles.

La capa de salida de la red utiliza la función de activación Softmax, lo que proporciona una salida de probabilidad para cada clase de mueble. La inclusión de capas de pooling ayuda a reducir la dimensionalidad, permitiendo que la red capture patrones más generales y mejore su capacidad de generalización. El modelo se entrenó utilizando un conjunto diversificado de imágenes de muebles, pasando por un riguroso proceso de validación para asegurar su eficacia.

3.2 Optimización de neuronas con algoritmo ABC

Se empleó el algoritmo ABC para la optimización y determinación del número óptimo de capas en la red neuronal. En este proceso, se mantuvo una estructura fija, variando únicamente un parámetro, denotado como "L", que correspondía al número de neuronas en la primera capa. Además, para las capas siguientes, este valor se multiplicó por 2 en la segunda capa y por 4 en la tercera capa. Esta estrategia de ajuste mediante el algoritmo ABC permitió explorar eficientemente diferentes configuraciones de capas, optimizando el rendimiento de la red neuronal.

Al ajustar únicamente el parámetro "L" y aplicar multiplicadores específicos en las capas subsiguientes, se logró una adaptación estructural que se alineó con los requisitos específicos del problema, contribuyendo así a la mejora general del desempeño de la red. Este enfoque de optimización también proporcionó una metodología sistemática para encontrar la configuración más eficiente en términos de rendimiento y eficacia en la tarea específica abordada.

3.3 Integración con SVM

Después de la extracción de características mediante la CNN, se implementó un clasificador SVM para la clasificación final. Se experimentó con diferentes configuraciones de SVM, ajustando parámetros como el tipo de kernel y el parámetro de regularización C, para optimizar el rendimiento del modelo en la clasificación de imágenes de muebles.

Asimismo, se experimentó con CNN explorando los clasificadores SVM (Support Vector Machines) de última generación como filtros fundamentales para la generación de mapas de características. Para llevar a cabo este enfoque innovador, implementamos una estrategia de aprendizaje supervisado hacia adelante que desempeñó un papel crucial en el cálculo de los pesos asignados a cada filtro.

Después de varias capas de convolución y reducción SVM, el razonamiento de alto nivel de la red se lleva a cabo mediante el entrenamiento de un clasificador SVM binario en las características de alto nivel extraídas de la última capa y cada mapa de hiper características

3.4 Uso de C-Means Fuzzy clustering

Fuzzy clustering se usa por su capacidad de segmentación de imágenes. Se utilizó para intentar identificar la mueblería. Además, dada la naturaleza del algoritmo en este caso k-means que nos dice que grado de pertenencia tienen los datos se podía usar para saber que era que y que más era. Es decir si era un sofá pero al tiempo era cama en este caso tiene pertenencia a dos clusters. Sin embargo, dada la naturaleza del data set usado que era tenía clases que no estaban balanceadas el algoritmo en nuestro caso no funcionó como se esperaba ni como la literatura mencionaba. Dando unos resultados demasiado bajos para considerarlos incluso aceptables.

3.5 Preprocesamiento de Datos

El proceso de preprocesamiento al que se sometieron las imágenes de mobiliario desempeñó un papel fundamental en la preparación de los datos para el entrenamiento del modelo. Este proceso de preprocesamiento incluyó la normalización de tamaño y color, así como técnicas de aumentación de datos como rotaciones y cambios de escala para mejorar la capacidad del modelo de generalizar a partir de nuevas imágenes.

4 Resultados de FurniRecon

La destacada eficacia de FurniRecon en la clasificación de imágenes de mobiliario queda evidenciada por sus resultados prometedores. El modelo ha demostrado un rendimiento notable al alcanzar una precisión del 70 % en el conjunto de validación. Esta tasa refleja la capacidad del modelo para reconocer y clasificar diversos tipos de mobiliario con un grado significativo de exactitud. En resumen, los resultados obtenidos por FurniRecon

son prometedores, proporcionando una base sólida para su aplicación en tareas de clasificación de imágenes de mobiliario. Su precisión y la capacidad de mejora a lo largo del entrenamiento lo posicionan como una herramienta valiosa en la identificación y categorización automatizada de muebles, con aplicaciones potenciales en la industria del diseño, el comercio electrónico de muebles y otras áreas relacionadas.

4.1 Desempeño del Modelo CNN

Durante la primera del experimento nos concentramos en desarrollar un modelo optimo de redes convolucionales, probamos diferentes parametros como la cantidad de capas (3 a 5), diferentes tipos de pooling (Maxpooling de 2x2 y 3x3), diferentes tipos de neuronas (iniciando en 32 y 128) encontrando que la mejor estructura (aplicando el principio de parsimonia), era una estructura de 32 neuronas iniciales, Maxpooling de (3,3) y 3 capas.

El modelo CNN mostró una capacidad consistente para clasificar diferentes categorías de muebles. La precisión y las métricas de clasificación indicaron un rendimiento satisfactorio (superior al 70%), especialmente en categorías como "Bed / bedroom item" y "Sofa / living room item", a continuación los resultados promedio de 6 corridas con la estructura seleccionada.

Table 1: Resultados para diferentes configuraciones de capas y neuronas

Clase/Configuración	3 Layers 3x3	3 Layers 2x2	5 Layers 3x3	128 neuronas
Cama	0.75	0.71	0.72	0.66
Sofa	0.73	0.71	0.66	0.72
Almacenamiento	0.53	0.43	0.43	0.56
Mesa	0.72	0.68	0.68	0.71

Table 2: Promedio de 5 corridas: Precision, Recall, y F1-score

Clase	Precision	Recall	F1-score
Cama	70.4%	75.4%	72.8%
Sofa	66.2%	73.8%	69.6%
Almacenamiento	59.8%	44.8%	50.0%
Mesa	72.4%	67.4%	69.6%
Promedio	67.2%	65.4%	65.5%

4.2 Optimización de neuronas por capa con Modelo ABC

Si bien nos enfocamos en crear una estructura eficiente en la primera etapa, queríamos comprobar que la estructura escogida era la mejor, para esto, utilizamos el algoritmo ABC en las dos corridas generadas con una población de 10 fuentes de comida y 3 abejas. Después de más de 12 horas de ejecución en ambas corridas, en las cuales utilizamos solo el 15% del dataset original, encontramos que el algoritmo converge a 24 neuronas iniciales (con el mejor fitness) en ambas ocasiones, los valores de L, la pérdida, el fitness y el total de trials se detallan en la Tabla 3, que muestra los resultados de la segunda corrida.

Table 3: Información de las corridas

Fuentes comida	L	Loss	Fitness	Trial
0	24	1.15	0.46	0
1	24	1.09	0.47	57
2	24	1.11	0.47	27
3	24	1.09	0.47	56
4	21	1.13	0.46	42
5	23	1.13	0.47	60
6	82	1.27	0.44	0
7	24	1.12	0.47	26
8	24	1.13	0.47	19
9	24	1.13	0.47	7

4.3 Resultados de la Integración CNN-SVM

Utilizando la estructura de la etapa inicial, y la mejor cantidad de neuronas encontradas con el algoritmo de optimización, realizamos un CNN+SVM, en el SVM probamos diferentes kernels, gammas y la constante C (sensibilidad de los errores), en resumen, el mejor modelo fue generado a partir de extraer las features maps del modelo CNN y entrenar con estas el SVM, con un kernel RBF sin modificar el gamma o el gamma predefinido.

Table 4: Corrida para SVM con Kernel RBF: Promedio SVM, Precision, Recall y F1-score, con diferencias porcentuales

Clase	Precision	Recall	F1	Dif.Precision	Dif. Recall	Dif. F1
Cama	75.5%	72.5%	73.5%	7%	-4%	1%
Sofa	75.5%	68%	71.5%	14%	-8%	3%
Almto.	59%	50.5%	54.5%	-1%	13%	9%
Mesa	75.5%	67%	71%	4%	-1%	2%

La integración del clasificador SVM con las características extraídas por la CNN resultó en una mejora de la precisión hasta llegar a un 75%, además mejoró un 9% la clasificación de almacenamiento, lo que destaca la eficacia de esta combinación en la mejora de la precisión y la generalización del modelo. La comparación entre el modelo CNN solo y el modelo combinado CNN-SVM reveló que la integración de SVM contribuye significativamente a la mejora del rendimiento del modelo, especialmente en términos de precisión y capacidad de generalización en la clasificación de imágenes de mobiliario, prueba de esto son las AUC de más del 88% en todas las clases.

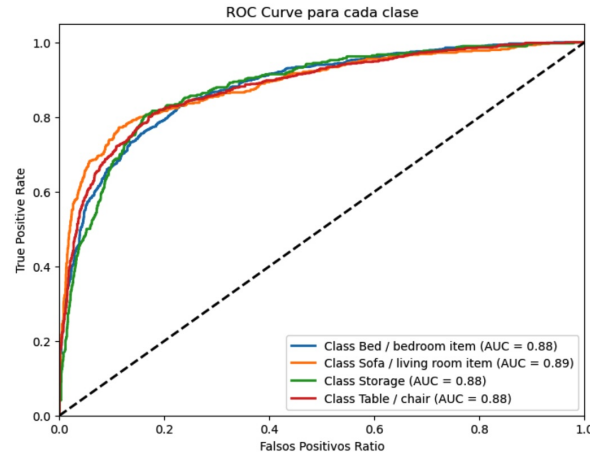


Fig. 4: Curva ROC y valores AUC.

4.4 Otros Experimentos

Utilizando el algoritmo de Fuzzy-clustering, confirmamos que los modelos más efectivos para el reconocimiento de imágenes son aquellos basados en redes convolucionales. Esto se debe a que, al tratarse de un modelo no supervisado, la ausencia de etiquetas deja la interpretación de la separación a discreción del modelo. Dado el carácter altamente heterogéneo del dataset, resultó casi imposible para el modelo asignar correctamente las imágenes a las etiquetas. La siguiente gráfica ilustra cómo los datos no están separados de manera adecuada, y no existe una distinción clara entre ellos. No utilizaremos medidas de desempeño, ya que el modelo no permite el cálculo de métricas como precisión o recall.




Fig. 5: C-Means Fuzzy clustering.

5 Discusión sobre FurniRecon

Los resultados de FurniRecon resaltan la efectividad de combinar redes neuronales convolucionales (CNN) con máquinas de soporte vectorial (SVM) en el ámbito del reconocimiento de imágenes de mobiliario. Esta amalgama ofrece una solución más robusta y precisa en comparación con los enfoques tradicionales, lo cual resulta crucial para aplicaciones en la industria del mobiliario. El estudio también subraya la importancia de la calidad de los datos y la diversidad del conjunto de datos en el rendimiento del modelo.

De esta manera, la tecnología transformará el mercado de diseño de interiores, y como se mencionó anteriormente, Colombia tiene la capacidad de exportar software, superando la exportación de hardware. Este podría ser el inicio de un mercado tecnológico que impulse al país hacia el desarrollo. Además, hemos observado un creciente

interés por parte del gobierno y el Ministerio de Tecnologías de la Información en la inteligencia artificial. Han creado mesas internacionales y participan como pioneros en usos gubernamentales en América Latina. Por lo tanto, la venta de software creado a través de capacidades de inteligencia artificial podría convertirse en un próspero mercado para el país, diversificando las exportaciones más allá de productos como petróleo, carbón y café (aunque estos son artículos principales).

6 Conclusiones de FurniRecon

FurniRecon representa un avance significativo en la aplicación de tecnologías de aprendizaje automático para el reconocimiento de imágenes de mobiliario. Este proyecto demuestra la viabilidad de utilizar una combinación de redes neuronales convolucionales (CNN) y máquinas de soporte vectorial (SVM) para mejorar la precisión y la generalización en la clasificación de imágenes. Estos hallazgos abren nuevas vías para la investigación y el desarrollo en la industria del mobiliario, sugiriendo que futuros estudios deberían enfocarse en explorar diferentes arquitecturas de modelos y expandir los conjuntos de datos para evaluar aún más la escalabilidad y la generalización de este enfoque.

La etapa de preprocesamiento de los datasets es vital, al igual que la recopilación de los mismos. Dado un dataset tan heterogéneo, no pudimos obtener precisiones o recall por encima del 90%, debido a la gran diversidad de imágenes, ángulos y colores presentes. Por otro lado, el uso de modelos no convolucionales al inicio de un ensamble no es recomendable, ya que la heterogeneidad conducía a resultados inconsistentes y arbitrarios. Además, aunque algunos filtros o procesamiento de imágenes podrían haber sido útiles, nos enfocamos directamente en mejorar el modelo inicial de redes convolucionales.

El algoritmo ABC resulta muy útil para garantizar, a través del método científico, la configuración óptima de una arquitectura de machine learning o inteligencia artificial. A pesar de la existencia de otros tipos de modelos evolutivos, la implementación del algoritmo ABC fue sencilla y arrojó resultados muy positivos; adicionalmente el uso del uso de SVM mejoró el desempeño de los CNN tal como se evidenció en la literatura y en los experimentos.

6.1 Implicaciones para Futuras Investigaciones

Si bien por temas de procesamiento los modelos generados fueron muy sencillos, el uso del algoritmo ABC puede ser utilizado con una mayor capacidad de cómputo con más abejas y población de comidas y sobretodo con el dataset completo, esto para generar un resultado real del mejor número de capas para la estructura inicial, o inclusive tener fuentes de comida con distintas arquitecturas.

Desde el SVM se observa que si bien mejoró el desempeño del algoritmo, una etapa de preprocesamiento o postprocesamiento beneficiaría aun más a este modelo, para que los hiperplanos creados no solo puedan generalizar más, si no encontrar particularidades en el dataset que diferencien mejor cada clase.

El algoritmo de fuzzy clustering debería ser usado exclusivamente en tareas de reconocimiento homogéneo por lo que no lo recomendamos en futuras investigaciones

de reconocimiento heterogeno, y si se llegase a utilizar en datasets heterogeneos, lo ideal es utilizarlo como un paso 2 en un ensamble, siempre dejando primero modelos de redes convolucionales que sean capaces de extraer features como paso uno y de esta manera mejorar la predicción actual.

References

- [1] Data growth worldwide 2010-2025 — Statista, <https://www.statista.com/statistics/871513/worldwide-data-created/>
- [2] Performance Development — TOP500, <https://www.top500.org/statistics/perfdevel/>
- [3] The Future of Jobs Report 2023, https://www.weforum.org/reports/the-future-of-jobs-report-2023/in-full?gclid=CjwKCAjwrranBhAEEiwAzbhNtb9yM2gLVpXsJM99ePD1-C9OK_KoDSsfHGnUcLm43s6RqPv7al0zwxoC_xcQAvD_BwE
- [4] Cioppi, M., Curina, I., Francioni, B., Savelli, E.: Digital transformation and marketing: a systematic and thematic literature review. *Italian Journal of Marketing*. 2023, 207–288 (2023). <https://doi.org/10.1007/s43039-023-00067-2>
- [5] Tan, Y.C., Chandukala, S.R., Reddy, S.K.: Augmented reality in retail and its impact on sales. *Journal of Marketing*. 86, 48–66 (2021). <https://doi.org/10.1177/0022242921995449>
- [6] Moreno, R.J., Sánchez, O.F.A., Ovalle, D.M.: Red neuronal convolucional para discriminar herramientas en robótica asistencial. *Visión Electrónica*. 12, 208–214 (2018). <https://doi.org/10.14483/22484728.13996>
- [7] Vista de Reconocimiento del abecedario de la lengua de señas colombiana con Redes Neuronales Convolucionales, <https://orinoquia.unillanos.edu.co/index.php/orinoquia/article/view/680/1218>
- [8] De Catalunya, U.O.: Diseño de un sistema de reconocimiento automático de matrículas de vehículos mediante una red neuronal convolucional, <https://openaccess.uoc.edu/handle/10609/52222>
- [9] Zhang, L., Luo, M., Liu, J., Li, Z., Zheng, Q.: Diverse fuzzy c-means for image clustering. *Pattern Recognition Letters*. 130, 275–283 (2020)(b). <https://doi.org/10.1016/j.patrec.2018.07.004>
- [10] L. Wardena, “Furniture Images Dataset,” Kaggle, Oct. 21, 2021. <https://www.kaggle.com/datasets/lasaljaywardena/furniture-images-dataset> (accessed Jul. 20, 2023).
- [11] R. Jiménez Moreno, O. Avilés, y D. M. Ovalle, *Red neuronal convolucional para discriminar herramientas en robótica asistencial*, *Vis. Electron.*, vol. 12, n.º 2, pp. 208–214, oct. 2018.

- [12] N. E. S. Rojas, B. S. M. Serna, E. M. P. Velásquez, and O. S. R. Galeano, “Reconocimiento del abecedario de la lengua de señas colombiana con Redes Neuronales Convolucionales,” *Orinoquia*, vol. 25, no. 1, pp. 25–30, Jun. 2021, doi: 10.22579/20112629.680.
- [13] U. O. De Catalunya, “Diseño de un sistema de reconocimiento automático de matrículas de vehículos mediante una red neuronal convolucional,” Jun. 01, 2016. <https://openaccess.uoc.edu/handle/10609/52222>
- [14] G. Beni and J. Wang, “Swarm intelligence in cellular robotic systems,” in *Springer eBooks*, 1993, pp. 703–712. doi: 10.1007/978-3-642-58069-7